

Comparação entre Algoritmos de Redução de Coeficientes para Modelagem de Amplificadores de Potência

Leonardo Nakatani Moretti¹, Luis Schuartz¹, Eduardo Lima¹ Grupo de Circuitos e Sistemas Integrados (GICS) – Departamento de Engenharia Elétrica, Universidade Federal do Paraná, Curitiba, Brasil

lnakatani@yahoo.com.br

Resumo—A modelagem de amplificadores de potência para pré-distorção digital é extremamente relevante no contexto moderno de redes sem fio. A redução da complexidade destes modelos e sua fidelidade estão diretamente atreladas. Esse trabalho busca comparar quatro diferentes algoritmos de redução, aplicados a três bases de modelagem de amplificadores de potência.

Palavras chave — Modelagem, pré-distorção digital, Séries de Volterra Polar, Amplificadores de potência.

I. INTRODUÇÃO

A crescente utilização de componentes sem fio e a utilização de redes que utilizam comunicação de radiofrequência tornam amplificadores de potência (PAs) peças extremamente relevantes no cenário tecnológico atual. Entretanto, a busca por eficiência [1] energética e a operação dos PAs em sua região linear faz com que haja parâmetros de interesse conflitante, eficiência energética e linearidade, uma vez que aumentar a linearidade, usualmente, implica em reduzir a eficiência energética.

Com essa perspectiva, a pré-distorção, mais especificamente a pré-distorção digital, busca obter as duas exigências simultaneamente [2]. Continuando os trabalhos de [3] e [4], que comparam diferentes bases usando apenas um algoritmo de redução, agora faz-se uma análise de como os diversos algoritmos discutidos em [5] se comportam com a utilização de bases mistas. Na Seção II trataremos das bases que foram utilizadas para modelar o comportamento do PA. Na Seção III trata-se dos algoritmos de redução que foram comparados. Na Seção IV trata-se da métrica utilizada e resultados. Na Seção V discute-se os resultados.

II. MODELAGEM

É observado que os modelos, em sua forma completa, tornam-se irrealisticamente complexos quando atingimos

números razoáveis de memória. Neste trabalho, portanto, utilizamos a versão bidimensional (2D) dos modelos. Isso significa que nenhum cálculo de coeficiente leva em consideração mais do que dois instantes de tempo.

A. Séries de Volterra Polar(PVS)

É impossível tratar de sistemas de memória desvanescente sem mencionar as séries de Volterra. Esse modelo matemático é muito bom para modelar PAs pois pode-se ajustar quanta memória seu modelo tem e é comumente usado na modelagem para pré-distorção digital. Entretanto esse modelo tem desvantagens, que é crescer muito rapidamente de complexidade conforme adicionamos mais elementos de memória. Dado isso, utilizamos uma versão reduzida, chamada de séries de Volterra 2D:

$$y^{cal}(n) = \sum_{p_{1}=1}^{p_{1}} \sum_{p_{2}=0}^{p_{1}-1} \sum_{m_{1}=0}^{M} \sum_{m_{2}=m_{1}+1}^{M} \sum_{p_{3}=1}^{P_{3}} \sum_{p_{4}=0}^{p_{3}-1} \sum_{p_{4}=0}^{M} \sum_{l_{1}=0}^{M} \sum_{l_{2}=l_{1}+1}^{P_{3}} \sum_{p_{5}=1}^{p_{5}-1} \sum_{p_{6}=0}^{L} \sum_{l_{3}=0}^{L} \sum_{l_{4}=l_{3}+1}^{L} , (1)$$

$$h_{p_{1},p_{2},p_{3},p_{4},p_{5},p_{6}}(m_{1},m_{2},l_{1},l_{2},l_{3},l_{4})a^{(p_{1}-p_{2})}(n-m_{1})a^{p_{2}}(n-m_{2})$$

$$\left[\left(e^{j\varphi(n-l_{1})}\right)^{p_{3}-p_{4}}\left(e^{j\varphi(n-l_{2})}\right)^{p_{4}}\right]\left[\left(e^{-j\varphi(n-l_{3})}\right)^{p_{5}-p_{6}}\left(e^{-j\varphi(n-l_{4})}\right)^{p_{6}}\right]$$

Onde P_1 e P_3 são valores de potência escolhidos, e M e L são valores de memória escolhidos, h é um coeficiente a ser escolhido, e a é o módulo do n-ésimo elemento das amostras.

Para manter (1) em sua forma 2D, é preciso aplicar uma restrição, na qual as informações utilizadas só podem se referir, simultaneamente, a dois instantes de tempo. Por exemplo, se m_1 =1 e m_2 =2, as outras variáveis só podem ser 1 ou 2.

B. Séries de diferença de ângulo modificada (MADS)

Essa base, tratada com mais detalhes em [3] e [4], é uma variação de PVS. Sua natureza mais simples permite com que o número de elementos de memória seja aumentado sem aumentar tanto a complexidade, quando comparada com PVS. Nesse trabalho, usaremos uma aplicação reduzida, em 2D:

$$y^{cal}(n) = \sum_{p_{1=1}}^{p_{1}} \sum_{p_{2}=0}^{p_{1}-1} \sum_{m_{1}=0}^{M} \sum_{m_{2}=m_{1}+1}^{M} \sum_{p_{3}=0}^{p_{3}} \sum_{l_{1}=0}^{L} \times \sum_{l_{2}=l_{1}+1}^{L} \left[h_{p_{1},p_{2},p_{3}}(m_{1},m_{2},l_{1},l_{2}) \right] \left[a^{(p_{1}-p_{2})}(n-m_{1}) \times a^{p_{2}}(n-m_{2}) \right] \left[\left(e^{j\varphi(n-l_{1})}e^{-j\varphi(n-l_{2})} \right)^{p_{3}} \left(e^{j\varphi(n)} \right) \right]$$
(2)

C. Série Conjunta (MIX)

Essa base, sugerida em [4], é a união de PVS e MADS. Quando aplicada por si só, ela não é uma base muito atraente, pois ela possui a complexidade somada das duas bases. Entretanto, quando consideramos algoritmos de redução, podemos verificar que há possíveis aplicações nessa base. Dado que uma base será reduzida por um algoritmo de redução, as combinações de coeficientes remanescentes são apenas os coeficientes de sua própria base. Ou seja, quando comparadas individualmente, espera-se que uma base seja superior a outra, dado um número de coeficientes reduzidos. Isso muda quando consideramos MIX, onde o algoritmo de redução tem acesso a duas bases diferentes, podendo então, para um número finito de coeficientes reduzido, escolher diferentes combinações das duas bases na qual MIX é composta.

III. ALGORITMOS DE REDUÇÃO

Como parâmetro de referência dos algoritmos, utilizamos o *Normalised Mean Square Error* (NMSE):

$$NMSE = 10log_{10} \left\{ \frac{\sum_{n=1}^{N} |y_n^{des} - y_n^{cal}|^2}{\sum_{n=1}^{N} |y_n^{des}|^2} \right\} \tag{3}$$

Esse parâmetro nos permite avaliar a proximidade do modelo calculado aos valores verdadeiros, portanto, é um indicador direto de quão boa foi a modelagem. Logo, utilizamos essa métrica para decidir quais coeficientes descartar.

Como tratado em [5], temos quatro algoritmos: incrementador, decrementador, ascendente e descendente.

A. Incrementador

No algoritmo incrementador ordena-se todos os coeficientes por ordem de contribuição individual e então seleciona-se os C coeficientes que mais contribuem individualmente para redução do NMSE.

B. Decrementador

No caso do decrementador, seleciona-se os coeficientes que contribuem menos individualmente e remove-os até restarem apenas C coeficientes.

C. Ascendente

No ascendente testa-se o coeficiente que mais contribui individualmente, e em seguida, testa-se os coeficientes já selecionados, adicionando um coeficiente a mais e calculando o NMSE da combinação dos coeficientes já selecionados com todas as opções remanescentes. Então seleciona-se a combinação que contribui mais para a redução do NMSE e se repete o processo, até selecionar-se C coeficientes.

D. Descendente

O descendente faz um processo similar, entretanto ele trata inicialmente de todos os coeficientes, então remove todas as opções de um coeficiente, e seleciona a combinação remanescente com menor NMSE, repetindo esse processo até atingir C coeficientes.

IV. RESULTADOS

Dados de entrada e saída foram coletados, usando um analisador vetorial de sinal da Rohde & Schwarz, de um PA GaN classe AB, com frequência central de 900 MHz e submetido a uma envoltória WCDMA de 3,84 MHz. A frequência de amostragem é de 30,72 MHz. Nos modelos utilizados usamos como truncamento das funções *M*=3, *L*=2, *P1*=5 e *P3*=2. Os algoritmos foram executados no *software* Matlab, usando aritmética de vírgula flutuante de precisão dupla. Os dados obtidos foram segmentados em dois conjuntos, uma parte foi utilizada para extração de coeficientes e a outra parte foi usada para a validação e teste dos algoritmos.

Como critério de avaliação dos resultados, calculamos o NMSE para cada uma das bases, para cada um dos algoritmos de redução, para vários valores de C. Pelos resultados do decrementador estarem significativamente longe dos outros algoritmos, decidiu-se mostrá-los separadamente, para facilitar a leitura.

As figuras 1 e 2 mostram o NMSE, em dB, em função do número de coeficientes C, para o algoritmo decrementador, para modelagem direta e inversa. Esse tipo de gráfico é útil para analisar quantos coeficientes podemos resolver, mantendo um nível de fidelidade aceitável, e comparar diferentes modelos para o mesmo C. Quanto mais baixo o valor de NMSE, melhor a fidelidade.

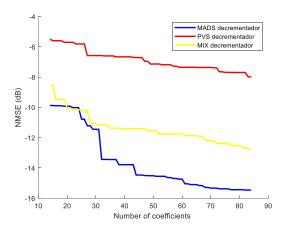


Fig. 1.NMSE x Número de coeficientes (direto, decrementador)

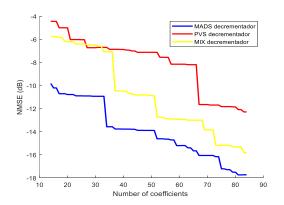


Fig. 2.NMSE x Número de coeficientes (inverso, decrementador)

Nas figuras 3 e 4 temos o NMSE, em dB, em função dos números de coeficientes, idêntico as figuras 1 e 2, entretanto dessa vez mostrando os resultados para os algoritmos incrementador, ascendente e descendente.

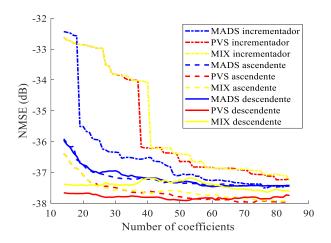


Fig. 3. NMSE x Número de coeficientes (direto)

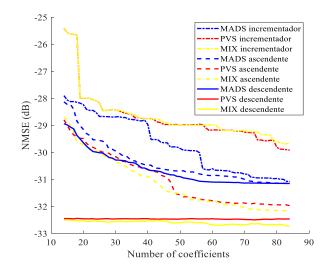


Fig. 4.NMSE x Número de coeficientes (inverso)

V. CONCLUSÃO

Há várias informações a serem obtidas da análise aplicada dos diversos algoritmos de redução nas bases utilizadas. Podemos observar que o desempenho do algoritmo decrementador é significativamente inferior do que todos os outros algoritmos, tanto que nenhum resultado obtido pelos outros algoritmos é superado por algum resultado obtido pelo método decrementador. Em seguida podemos verificar que, quando se trata do modelo incrementador, que é o segundo pior em desempenho, o modelo MADS supera tanto o PVS quanto o MIX. Entretanto esse resultado não é interessante pois os valores obtidos ainda são consideravelmente inferiores do que os valores obtidos pelos algoritmos descendente e ascendente.

Quando tratando dos algoritmos descendente e ascendente, temos resultados inesperados. Para a modelagem direta, temos o PVS descendente com melhores resultados para grande parte dos valores de C, entretanto pode-se observar que os algoritmos ascendentes superam o modelo descendente para números grandes de C (maior que 60).

Enquanto isso, na modelagem inversa, temos os melhores resultados em MIX descendente, que nesse caso, tem resultados melhores que todos os outros modelos e algoritmos para todos os valores observados de C.

Tendo essa informação em mente, sabemos que quando utilizando a modelagem inversa, é preferível se utilizar bases mistas em combinação com o algoritmo de redução descendente, enquanto na modelagem direta, deve-se avaliar qual a melhor opção para o número de C que foi escolhido.

Ademais, pode-se tomar como conclusão que, para modelos 2D, o algoritmo decrementador não deve ser utilizado, e o incrementador tem resultados marginais, se comparado com os modelos ascendentes e descendentes.

Entretanto, vale-se observar que esses modeles tem complexidade e tempo de computação significativamente maior do que os modelos incrementadores e decrementadores.

AGRADECIMENTOS

Esse estudo foi financiado em parte pela Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Finança 001 e Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq).

REFERÊNCIAS

- [1] S. Cripps, RF Power Amplifiers for Wireless Communications, 2nd edition. Norwood, MA: Artech House, 2006.
- [2] P. B. Kenington, High Linearity RF Amplifier Design. Norwood, MA: Artech House, 2000.
- [3] Moretti, L. N.; Schuartz, L.; Lima, E. G. . Incrementally Reduced Angle Difference and Polar Volterra Series for Power Amplifier Modeling. 34th South Symposium on Microelectronics, 2019, Pelotas - RS.
- [4] Moretti, L. N.; Schuartz, L.; Lima, E. G. Mixed Coefficients from Different Bases for Power Amplifier Modeling. XIX Microelectronics Students Forum, 2019, São Paulo. XIX Microelectronics Students Forum, 2019.
- [5] SCHUARTZ, L.; SANTOS, E. L.; LEITE, B. R. B. A.; MARIANO, A. A.; LIMA, E. G. Reduced-Complexity Polynomials with Memory Applied to the Linearization of Power Amplifiers with Real-Time Discrete Gain Control. CIRCUITS SYSTEMS AND SIGNAL PROCESSING, 2019.